


Métodos de Aprendizagem Não Supervisionada

2º ano da Licenciatura de Ciência de Dados

Relatório do Trabalho

PCA e Clustering na Análise de Sinistros Automóvel



Grupo PLGr03

Paula Cristina Relvas N.º 43905

Leandro Bernardo N.º 125293

Pedro Miguel Gonçalves N.º 130668

Tiago Oeber N.º 130667

dezembro, 2025

INTRODUÇÃO

As seguradoras operam sobre carteiras de clientes marcadamente heterogéneas, tanto ao nível das características dos segurados como das características dos sinistros, que apresentam elevada variabilidade em termos de severidade e impacto financeiro. Esta diversidade dificulta a compreensão dos padrões de sinistralidade e a antecipação do risco associado a diferentes perfis.

Este trabalho tem como objetivo identificar tipologias homogéneas de sinistros através da análise dos dados, com vista a antecipação os padrões de sinistralidade.

A identificação de tipologias de sinistros constitui um instrumento central da gestão atuarial, permitindo uma tarifação mais ajustada ao risco, uma melhor alocação de recursos e um reforço dos mecanismos de controlo e prevenção. A segmentação baseada em dados possibilita diferenciar grupos com comportamentos substantivamente distintos, aumentando a eficiência e a equidade das decisões tomadas.

Nós recorremos à Análise em Componentes Principais (PCA) para reduzir a dimensionalidade e captar a estrutura dos dados, seguida de técnicas de clustering para agrupar sinistros com padrões semelhantes. Esta perspetiva permite explorar a informação de forma exploratória e indutiva, revelando estruturas subjacentes que não são diretamente observáveis.

DADOS

A análise baseou-se numa amostra de 892 sinistros automóveis registados entre 1 de janeiro e 1 de março de 2015 (inclusive), correspondentes ao subconjunto do Grupo 3 da turma pós-laboral. Após remoção das variáveis binárias de seleção de grupo, a base de dados final compreende 24 variáveis distribuídas:

- Característica do segurado: idade, Número de meses como cliente, género, educação, ocupação, hobbies, relação entre o portador da apólice e o condutor na altura do incidente.
- Variáveis do incidente: data, hora, tipo de incidente, severidade, tipo de colisão, autoridades contactadas, veículos envolvidos, ferimentos, testemunhas, danos materiais, disponibilidade do relatório policial.
- Variáveis de indemnizações: indemnização de danos corporais, de danos materiais, do veículo e indemnização total.
- Variáveis do veículo: marca do veículo, ano de produção do veículo.

Existem 12 variáveis quantitativas e 12 variáveis qualitativas, os dados mencionados estão descritos na Tabela 4 e Tabela 5 respetivamente.

- Descrição do cliente: O cliente tem um perfil demográfico maduro com idade média de 39 anos e sendo cliente da seguradora durante 205 meses em média, existe uma distribuição de género relativamente igual, com 54,5% dos clientes média serem mulheres e maior.
- Descrição dos sinistros: A pluralidade dos sinistros (35,7%) mostra uma severidade com poucos danos.
- Descrição das indemnizações: A distribuição de indemnizações apresenta cauda longa à direita e forte assimetria positiva (valores médios de 53.031€ mas amplitude entre 100€ e 114.920€).

ESCOLHA DE INPUT E PROFILE

Foram escolhidas as variáveis ativas/input¹ baseado em princípios teóricos, foram as variáveis que influenciaram e que detalharam os incidentes, por exemplo `number_of_vehicles_involved` pode indicar a escalabilidade dos incidentes, o mês do `incident_date` pode indicar se o incidente foi afetado pela sazonalidade e o clima, a `incident_hour_of_the_day` pode indicar se o incidente foi afetado pelo ciclo dia-noite.

As variáveis passivas/profile são as variáveis que não afetam o incidente e podem descritas baseado nos inputs, por exemplo, os `witnesses` podem ser explicados pelos `bodily_injuries` e `number_of_vehicles_involved`, mas não tem covariância suficiente para o PCA.

A Tabela 1 - Tipos de variáveis utilizadas mostra as variáveis utilizadas nos inputs e profile.

Variáveis de input/ativas	<code>number_of_vehicles_involved</code> , <code>injury_claim</code> , <code>property_claim</code> , <code>vehicle_claim</code> , <code>incident_severity</code> , <code>incident_type</code> , <code>authorities_contacted</code> , <code>bodily_injuries</code> , <code>incident_date</code>
Variáveis de profile/passivas	<code>months_as_customer</code> , <code>age</code> , <code>insured_sex</code> , <code>insured_education_level</code> , <code>insured_occupation</code> , <code>insured_hobbies</code> , <code>insured_relationship</code> , <code>auto_make</code> , <code>auto_year</code> , <code>witnesses</code> , <code>property_damage</code> , <code>police_report_available</code> , <code>incident_date</code> , <code>incident_hour_of_the_day</code>
Variáveis ignoradas	<code>incident_date</code> ² , <code>total_claim</code>

Tabela 1 - Tipos de variáveis utilizadas

PCA

TRATAMENTO DE VALORES OMISSOS

¹ Input são as variáveis que determinam a estrutura do agrupamento.

² O ano do incidente pode ser ignorado, mas o mês pode ser útil.

Antes da aplicação do PCA, foi feita a preparação do conjunto de dados para assegurar que as variáveis estavam sem valores vazios e sem valores inconsistentes para serem utilizadas na análise, o processo inicial envolveu transformar os valores de transformar todas valores “?”, “”(vazios) em valores do tipo NA (nulos), a quantidade de valores missing por variável pode ser visto na Figura 1. O tratamento de valores missing pode ser vista na Tabela 2.




Figura 1 - Distribuição dos valores NA

Variável	Processo de lidar com os missings	Justificação
<i>property_damage</i>	Tornar NA em Other	As variáveis são binárias; no entanto, o significado exato dos valores em falta não é conhecido. Como estas variáveis não foram utilizadas no PCA, optou-se por manter a informação para a etapa de <i>clustering</i> , sem necessidade de normalização ou imputação numérica.
<i>police_report_available</i>	Tornar NA em Other	
<i>authorities_contacted</i>	Tornar NA em “No authorities contacted”	Não existe uma categoria explícita que represente a ausência de contacto com as autoridades. Assim, assume-se que os valores

		em falta correspondem a situações em que não houve contacto, hipótese consistente com a estrutura da variável.
<i>Incident_type</i>	Tornar NA em “No collision”	Os valores NA estão no enunciado descritos como “no collision” nesta variável logo NA foi convertido em no collision

Tabela 2 - tratamento de valores missing

incident_type	collision_type
Vehicle Theft	?
Multi-vehicle Collision	Rear Collision
Multi-vehicle Collision	Rear Collision
Multi-vehicle Collision	Front Collision
Single Vehicle Collision	Rear Collision
Vehicle Theft	?
Parked Car	?

Figura 2 - Amostra do `incident_type` e `collision_type`: quando as colisões são “?”, o tipo de incidente é roubo ou multas pelo carro estar mal-estacionado.

TRATAMENTO DE OUTLIERS

Foram detetados os outliers através do intervalo interquartil (IQR em inglês), existem 10 outliers no dataset em 3 variáveis das indemnizações, estas podem ser vistos no Figura 3.




Figura 3 - boxplot das variáveis com outliers

As observações que continham estes outliers foram removidas, uma vez que representam uma fração muito reduzida do conjunto de dados, não comprometendo a informação global. Esta decisão teve como objetivo evitar enviesamentos nos resultados da Análise em Componentes Principais (PCA), dado que esta técnica é sensível a valores extremos.

CODIFICAÇÃO DAS VARIÁVEIS CATEGÓRICAS

A codificação das variáveis categóricas é necessária para a aplicação do PCA, uma vez que esta técnica se baseia em operações sobre variáveis numéricas.

- A codificação das variáveis categóricas nominais foi feita com One-Hot Encoding³.
- A codificação das variáveis categóricas ordinais foi feita com conversão à escala numérica por ordem das ordinais. Exemplo:

[*“Trivial Damage”* → 1, *“Minor Damage”* → 2, ... , *“Total Loss”* → 4]

A Tabela 3 mostra as variáveis específicas e métodos utilizados.

Variáveis categóricas a codificar	Tipo de variável categoria	Forma de normalização
collision_type	Nominal	One-Hot Encoding
incident_severity	Ordinal	Conversão em escala numérica
authorities_contacted	Nominal	One-Hot Encoding
incident_type	Nominal	One-Hot Encoding

Tabela 3 – Variáveis e codificação

ESCOLHA DAS VARIÁVEIS USADAS PARA O PCA

Para selecionar as variáveis a utilizar no PCA, recorreu-se à medida de Kaiser–Meyer–Olkin (KMO), que corresponde à média das medidas de adequação da amostra (MSA) individuais. As variáveis foram avaliadas com base no MSA individual, sendo removidas aquelas com valores inferiores a 0,5 sempre que a sua exclusão melhorava o valor global do KMO.

De acordo com a literatura, valores de KMO superiores a 0,8 indicam uma excelente adequação dos dados ao PCA. Neste estudo, obteve-se um KMO global de 0,83, confirmando a qualidade do conjunto de variáveis selecionado. Os valores individuais de MSA encontram-se apresentados na Figura 4. Além disso como o teste de bartestt tem p value significativo abaixo de 0.5 (p-value ≈ 0), podemos confirmar a normalidade multivariada. Assim podemos confirmar que o PCA pode ser aplicado ao nosso dataset.

Nota: após vários testes, foi selecionado um subconjunto de variáveis binárias que maximiza a informação relevante sobre as variáveis *authorities_contacted*, *collision_type* e *incident_type* e minimiza problemas de multicolinearidade, respetivamente: *No_authorities*, *Multi_vehicle_collision* e *Parked_car*.

³ Para uma variável categórica com k categorias, o One-Hot Encoding cria k novas variáveis binárias (0/1).




Figura 4 - MSA por variável

ESCOLHA DE COMPONENTES

A escolha do número de componentes principais (PCs) baseou-se sobretudo na análise das rotações e na interpretabilidade dos loadings (Figura 8). Embora, segundo o critério de Kaiser, o terceiro componente principal (PC3) apresente um valor próprio inferior a 1 (Figura 5), optou-se por reter este componente adicional, uma vez que a variância explicada acumulada atingiu 0,744 (Figura 6), ultrapassando o limiar mínimo de retenção de 0,6. Esta decisão é também sustentada pela observação do scree plot (Figura 7), onde se verifica um abrandamento claro na diminuição dos valores próprios após o terceiro componente.

Relativamente à rotação, foi selecionada a rotação Promax⁴. Após várias tentativas com diferentes métodos de rotação, esta revelou-se a mais adequada, por proporcionar uma estrutura mais simples e interpretável, facilitando a análise e a interpretação dos componentes extraídos.

⁴ A rotação promax é um método de rotação oblíqua cujo principal objetivo é facilitar a interpretação dos fatores ou componentes, permitindo que estes apresentem correlação entre si. Este tipo de rotação é particularmente adequado em contextos nos quais se admite que as dimensões latentes subjacentes aos dados não são independentes. O procedimento da rotação promax inicia-se, regra geral, com a aplicação de uma rotação varimax, que é uma rotação ortogonal, utilizada para obter uma solução inicial simples e estruturada. Posteriormente, os loadings fatoriais resultantes são elevadas a uma determinada potência, normalmente compreendida entre 2 e 4, com o intuito de reforçar os valores mais elevados e atenuar os valores mais baixos. Este processo contribui para uma maior diferenciação das associações entre variáveis e fatores, tornando a estrutura fatorial mais clara.

4.741 1.620 0.741 0.653 0.434 0.430 0.233 0.116 0.031

Figura 5 – Variância dos componentes, critério de Kaiser

	RC3	RC1	RC2
SS loadings	2.403	2.317	1.981
Proportion Var	0.267	0.257	0.220
Cumulative Var	0.267	0.524	0.744

Figura 6 - Variância explicada




Figura 7 - Screeplot dos dados

Loadings:			
	RC3	RC1	RC2
incident_severity	0.840	-0.129	
injury_claim		0.919	
property_claim		0.861	
vehicle_claim	0.280	0.738	
number_of_vehicles_involved			0.996
Multi_vehicle_Collision			0.990
Parked_Car	-0.837		
Collision	0.597	0.402	
No_authorities	-0.745		

Figura 8 - Interpretação dos componentes

Cada componente agrega variáveis com padrões de comportamento semelhantes, possibilitando a identificação de estruturas latentes relevantes para a descrição dos sinistros.

- PC1: A primeira componente, designada **Indemnizações**, é predominantemente determinada pelas variáveis associadas aos montantes reclamados em indemnizações, nomeadamente *injury_claim*, *property_claim*, *vehicle_claim* e *Collision*. Estas variáveis tendem a variar de forma conjunta, uma vez que sinistros que envolvem danos corporais são frequentemente acompanhados por prejuízos materiais e custos de reparação dos veículos. Adicionalmente, a variável *Collision* encontra-se relacionada com as restantes, na medida em que colisões de maior intensidade tendem a originar valores mais elevados de indemnização. No seu conjunto, esta

Com base nesta matriz transformada, é então estimada uma rotação oblíqua que melhor se ajusta aos dados em análise, permitindo obter uma solução mais interpretável e teoricamente consistente.

componente traduz o impacto financeiro do sinistro, concentrando a informação relativa ao volume global das indemnizações associadas.

- PC2: A segunda componente, designada **Veículos**, está associada às variáveis que descrevem características dos veículos envolvidos, em particular *number_of_vehicles_involved* e *multi_vehicle_Collision*. Um maior número de veículos envolvidos num acidente está, em geral, associado a situações que incluem colisões de múltiplos veículos.
- PC3: a terceira componente, denominada **Incidentes Graves**, agrega variáveis indicativas da intensidade e do contexto do sinistro, nomeadamente *incident_severity*, *Collision*, *Parked_car* e *No_authorities*. Esta componente apresenta uma particularidade relevante, uma vez que nem todas as variáveis se relacionam positivamente com o fator subjacente. Enquanto *incident_severity* e *Collision* apresentam cargas positivas, as variáveis *Parked_car* e *No_authorities* exibem cargas negativas. Assim, valores mais elevados desta componente correspondem a sinistros mais severos e com maior intensidade de colisão, ao mesmo tempo que estão associados a uma menor probabilidade de se tratar de um incidente envolvendo um veículo estacionado e a uma maior probabilidade de contacto com as autoridades.

Apesar de esta última componente poder aparentar a agregação de duas dimensões distintas, a exploração de uma solução alternativa com quatro componentes revelou-se pouco adequada. Nessa configuração, a terceira componente mantinha essencialmente as variáveis, com exceção de *incident_severity*, que passava a constituir isoladamente a quarta componente. Uma vez que não é metodologicamente justificável a retenção de uma componente composta por uma única variável, optou-se pela solução com três componentes principais, considerada mais parcimoniosa e interpretável.

IDENTIFICAÇÃO DA HETEROGENEIDADE NA BASE DE DADOS

ESCOLHA DO MÉTODO

Após a redução das variáveis de input em três componentes principais, procedeu-se à aplicação de clustering hierárquico sobre os scores dos PCs, uma vez que estes são variáveis contínuas, não correlacionadas e previamente normalizadas, sendo adequadas a métodos baseados em distâncias.

CÁLCULO DE DISTÂNCIAS

Para o cálculo das distâncias entre observações, foi utilizada a distância de Manhattan, por ser mais robusta a valores extremos e adequada a dados transformados e normalizados. A formação dos clusters foi realizada recorrendo ao método de ligação average linkage, que apresenta um compromisso entre a compactação interna dos clusters e a separação entre grupos.

A escolha desta combinação resultou de um processo exploratório e iterativo, no qual foram comparados diferentes métodos de distância e ligação, tendo esta abordagem apresentado a melhor qualidade de clustering e maior coerência interpretativa para os objetivos do estudo.

NÚMERO DE CLUSTERS

Para determinar o número ótimo de clusters, recorreu-se à análise da largura média da Silhouette, complementada pela visualização do gráfico da Silhouette (Figura 9) e pela inspeção do dendrograma. Com base nestes critérios, concluiu-se que a solução com três clusters é a mais adequada, apresentando uma largura média da Silhouette de aproximadamente 0,53, indicativa de uma separação razoável entre grupos (Figura 10).




Figura 9 – dendrograma dos clusters




Figura 10 - silhouete do clustering

NOMES DOS CLUSTERS

A Figura 11 apresenta a distribuição das componentes principais por cluster, permitindo analisar as diferenças estruturais entre os grupos identificados através do clustering hierárquico aplicado aos scores dos PCAs.

Com base nos valores centrais (mediana) e na dispersão das componentes principais em cada grupo, foram identificados **três clusters com perfis distintos**, os quais foram interpretados e denominados de acordo com as características predominantes.

O Cluster 1, designado Acidentes Simples (AS), caracteriza-se por valores predominantemente negativos na componente Número_veículos, indicando acidentes com um número reduzido de veículos envolvidos. As indemnizações associadas apresentam valores moderados, refletindo eventos de menor complexidade e impacto económico limitado. Este cluster integra 355 observações.

O Cluster 2, denominado Acidentes Complexos com Alto Custo (ACAC), apresenta valores elevados nas componentes Número_veículos e Indemnizações, evidenciando acidentes com maior complexidade estrutural e elevados montantes indemnizatórios. Trata-se do cluster mais representativo, com 374 observações, correspondendo a ocorrências de maior severidade económica.

O Cluster 3, designado Acidentes com Baixo Custo (ABC), distingue-se por valores negativos na componente Indemnizações, indicando custos reduzidos associados aos acidentes. O número de veículos envolvidos assume valores próximos do centro da distribuição, sugerindo um papel menos determinante desta componente na definição do grupo. Este cluster é o menos numeroso, com 154 observações.

A componente Gravidade_acidentes não foi utilizada no processo de clustering, uma vez que apresentou baixa correlação com as restantes componentes principais, não contribuindo de forma relevante para a separação dos grupos. Adicionalmente, a utilização de apenas duas componentes principais conduziria a uma distribuição desequilibrada das variáveis originais entre os PCs, comprometendo a interpretabilidade e a representatividade dos clusters.




Figura 11 - Distribuição dos PCs por clusters

ANÁLISE DOS CLUSTERS BASEADO NAS VARIÁVEIS PROFILE

De um modo geral, os três clusters apresentam perfis etários semelhantes (figura 17), com medianas próximas e dispersões comparáveis. O cluster 2 tende a concentrar ligeiramente indivíduos mais velhos, enquanto o cluster 3 apresenta idades um pouco mais baixas, mas sem diferenças muito marcadas. Isto indica que a idade não é o principal fator de separação entre os grupos.

Relativamente ao género (figura 20), os três clusters mostram uma distribuição equilibrada entre homens e mulheres, com uma ligeira predominância do género feminino em todos eles. Não se observa um cluster claramente associado a um único género.

Quanto à situação profissional (figura 11), surgem diferenças mais visíveis. O cluster 1 apresenta maior proporção de trabalhos físicos, enquanto o cluster 3 concentra relativamente mais indivíduos em ocupações cognitivas. O cluster 2 situa-se numa posição intermédia, sugerindo um perfil profissional mais misto.

No que diz respeito aos danos materiais (figura 23), o cluster 1 apresenta uma maior proporção de casos sem danos, enquanto o cluster 3 tem uma percentagem relativamente mais elevada de situações com danos confirmados. O cluster 2 volta a surgir como intermédio, com uma distribuição mais equilibrada entre as categorias.

Analisando os ferimentos (figura 21), o cluster 3 tende a concentrar situações com menor gravidade, ou seja, menos feridos causados no acidente, enquanto os clusters 1 e 2 apresentam maior número de feridos.

Em termos temporais, os clusters diferenciam-se ligeiramente. O cluster 1 está mais associado a acidentes ocorridos durante o dia (figura 18), enquanto o cluster 3 mostra maior concentração em horários tardios. A distribuição por meses (figura 22) não evidencia ruturas claras, porem este resultado era esperado devido ao facto de os nossos dados só variarem entre 1 de Janeiro e 1 de Março.

Relativamente à presença policial (figura 15) e de testemunhas (figura 12), o cluster 3 apresenta menor frequência de contacto com autoridades e existência de testemunhas.

CONCLUSÃO

A maximização sustentável do lucro numa seguradora depende da capacidade de antecipar o custo dos sinistros, compreender a sua complexidade operacional e identificar os segmentos que mais pressionam a margem. Este estudo respondeu a estas necessidades ao transformar um conjunto disperso de variáveis operacionais em dimensões interpretáveis e, posteriormente, em segmentos acionáveis, permitindo passar de uma análise caso a caso para uma visão estruturada do portefólio de sinistros.

A aplicação do PCA permitiu sintetizar a informação em componentes alinhadas com a lógica de negócio: uma dimensão associada às indemnizações, refletindo a pressão direta sobre a sinistralidade; uma dimensão relacionada com o número de veículos envolvidos, proxy da complexidade do acidente e dos custos de gestão; e uma componente de gravidade com comportamento mais independente. Com base nos scores destas componentes, o clustering identificou três grupos estáveis e interpretáveis: Acidentes Simples (AS), Acidentes Complexos com Alto Custo (ACAC) e Acidentes com Baixo Custo (ABC). O portefólio concentra-se maioritariamente nos dois primeiros clusters, sendo o ACAC particularmente relevante por combinar elevada frequência com elevado custo médio, tornando-se o principal determinante do risco económico global.

Do ponto de vista da decisão futura, os resultados indicam que a margem da seguradora não deve ser analisada de forma agregada, mas sim por cluster. O cluster ACAC representa a principal alavanca de intervenção, exigindo políticas específicas de controlo de custos, triagem prioritária, gestão especializada de sinistros complexos e maior granularidade nas decisões de pricing e underwriting. Por

contraste, o cluster AS oferece oportunidades claras de eficiência operacional através de automatização e processos simplificados, enquanto o cluster ABC exige uma gestão de baixo custo para evitar que despesas administrativas comprometam a rentabilidade de sinistros de menor valor.

A separação clara entre variáveis de input e variáveis de perfil reforça a robustez dos resultados e permite utilizar os clusters como base para ações estratégicas adicionais, como programas de prevenção, comunicação dirigida e ajustamento do desenho de produtos, sem enviesar o processo de segmentação. Tecnicamente, a utilização de PCA seguida de clustering sobre componentes não correlacionadas assegura estabilidade dos grupos e facilita a sua integração em sistemas de apoio à decisão.

Concluindo, o estudo demonstra que o portefólio de sinistros é segmentável em padrões consistentes e economicamente relevantes. A recuperação e maximização da margem dependem de uma gestão diferenciada por cluster, com métricas e estratégias próprias, substituindo abordagens uniformes por uma arquitetura de decisão orientada por dados, com impacto direto na rentabilidade e sustentabilidade da seguradora.

BIBLIOGRAFIA

<https://personal.utdallas.edu/~herve/Abdi-rotations-pretty.pdf>

ANEXOS

Variável	Significado	Amplitude dos valores	Estatísticas Descritivas
<i>months_as_customer</i>	Número de meses como cliente	[0, 479]	Média: 205.2 Mediana: 200.5
<i>age</i>	Idade do cliente	[19, 64]	Média: 39.0 Mediana: 38.0
<i>incident_date</i>	Data da ocorrência do incidente (tipo - timestamp)	[01/01/2025 - 01/03/2025]	
<i>Auto-year</i>	Ano de produção do veículo	[1995, 2015]	Média: 2005 Mediana: 2005
<i>incident_hour_of_the_day</i>	Hora do sinistro	[0, 23]	Média: 11.7 horas Mediana: 12.0
<i>number_of_vehicles_involved</i>	Número de veículos envolvidos	[1, 4]	Média: 1.85 Mediana: 1.0
<i>bodily_injuries</i>	Número de feridas corporais	[0, 2]	Média: 1.0 Mediana: 1.0
<i>witnesses</i>	Número de testemunhas	[0, 3]	Média: 1.48 Mediana: 1.0
<i>injury_claim</i>	Indeminização de dados corporais	[0, 21 450]	Média: 7,513 Mediana: 6,820
<i>property_claim</i>	Indeminização de dados materiais	[0, 23 670]	Média: 7,396 Mediana: 6,760
<i>vehicle_claim</i>	Indeminização de dados dos veículos	[70, 79 590]	Média: 38,123 Mediana: 42,295
<i>total_claim_amount</i>	Valor total de indenização	[100, 114 920]	Média: 53 031 Mediana: 58 250

Tabela 4 - Variáveis quantitativas⁵

Variável	Descrição	Tipo de categórica	Valores	Frequências relativas
----------	-----------	--------------------	---------	-----------------------

⁵ Todas as variáveis quantitativas são discretas

<i>insured_sex</i>	Sexo do segurado	Nominal	[Male, Female]	FEMALE: 54.5%, MALE: 45.5%
<i>insured_education_level</i>	Nível educacional do segurado	Ordinal	[JD, High School, MD, Masters, Associate, College, Phd]	JD: 15.8%, High School: 15.7% MD: 14.6%, Masters: 14.5% Associate: 14.1%, PhD: 13.1%, College: 12.2%
<i>insured_occupation</i>	Profissão do segurado	Nominal	[craft-repair, sales, tech-support ,prof-specialty, ...]	
<i>insured_hobbies</i>	Hobbies do segurado	Nominal	[sleeping, golf,camping, dancing, skydiving, reading, Movies, ...]	
<i>insured_relationship</i>	Relação segurado-condutor	Nominal	[husband, wife, own-child, unmarried,...]	
<i>incident_type</i>	Tipo de incidente	Nominal	[Multi-vehicle, Single Vehicle, Vehicle Theft, Parked car]	Multi-vehicle: 42.5%, Single Vehicle: 40.1%, Vehicle Theft: 8.9%, Parked Car: 8.5%
<i>collision_type</i>	Tipo de colisão	Nominal	[Front collision, Side collision, rear collision]	Front/Side/Rear Collision ?: para non-collision
<i>incident_severity</i>	Severidade de incidente	Ordinal	[Trivial damage, Minor damage, Major damage, Total Loss]	Minor Damage: 35.7% Total Loss: 27.8% Major Damage: 27.5%, Trivial Damage: 9.1%
<i>authorities_contacted</i>	Indeminização de dados dos veículos	Nominal	[Police, Fire Ambulance, Other, None]	
<i>property_damage</i>	Ocorrência de danos materiais	Nominal	[YES, NO]	YES: 29.7% NO: 33.9%
<i>police_report_available</i>	Disponibilidade do relatório policial	Nominal	[Yes, No]	YES: 30.4% NO: 34.3%
<i>Auto-make</i>	Marca do veiculo	Nominal	[Saab, Nissan, Audi,...]	

Tabela 5 - variáveis qualitativas




Figura 12 - Gráfico entre as ocupações e os clusters




Figura 13 — Gráfico entre o número de testemunhas e os clusters




Figura 14 - Gráfico entre o nível de educação e os clusters




Figura 15 - Gráfico entre as relações familiares e os clusters




Figura 16 - Gráfico entre a existência de relatórios policiais e os clusters




Figura 17 - Gráfico entre a quantidade de meses como cliente e os clusters




Figura 18 - Gráfico entre as idades dos clientes e os clusters




Figura 19 - Gráfico entre as horas do acidente cometido e os clusters




Figura 20 - Gráfico entre os tipos de hobbies e os clusters




Figura 21 - Gráfico entre o género dos clientes e os clusters




Figura 22 - Gráfico entre o número de vítimas feridas e os clusters




Figura 23 - Gráfico entre a data do acidente e os clusters




Figura 24 - Gráfico entre a existencia dos danos na propriedade e os clusters




Figura 25 - Gráfico entre os tipos de carros (baseado nas marcas deles) e os clusters




Figura 26 - Gráfico entre o ano de produção dos carros e os clusters